Московский Авиационный Институт
(Национальный Исследовательский
Университет)

Факультет: «Информационные технологии и прикладная математика»

Дисциплина: «Искусственный интеллект»

Лабораторная работа №1

Студент	Ермакова А.Н.
Группа	М8О-301Б-19
Дата	8.05.2022
Оценка	

Москва, 2022

Работа посвящена реализации алгоритмов машинного обучения, проверке точности различных моделей при переборе гиперпараметров и обучению работе как со встроенными функциями библиотек так и с собственными реализациями. Определения модели и ее параметров для достижения наиболее высокой точности при предсказании на тестовой выборке является главной целью лабораторной работы.

Постановка задачи:

1) реализовать следующие алгоритмы машинного обучения: Linear/ Logistic Regression, SVM, KNN, Naive Bayes в отдельных классах
2) Данные классы должны наследоваться от BaseEstimator и ClassifierMixin, иметь методы fit и predict
3) Вы должны организовать весь процесс предобработки, обучения и тестирования с помощью Pipeline
4) Вы должны настроить гиперпараметры моделей с помощью кросс валидации , вывести и сохранить эти гиперпараметры в файл, вместе с обученными моделями
5) Проделать аналогично с коробочными решениями
6) Для каждой модели получить оценки метрик:Confusion Matrix, Accuracy, Recall, Precision, ROC_AUC curve
7) Проанализировать полученные результаты и сделать выводы о применимости моделей
8) Загрузить полученные гиперпараметры модели и обученные модели в формате pickle на гит вместе с jupyter notebook ваших экспериментов

Ход решения:
1. Загрузка данных
2. Реализация Pipeline для предобработки
3. Логистическая регрессия (моя реализация, Pipeline для обучения и тестирования, Обучение и тестирование для моей модели, Обучение и тестирование для sklearn модели, перебор различных гиперпараметров с кросс-валидацией, оценка модели, сохранение результатов)

4. KNN (моя реализация, Pipeline для обучения и тестирования, Обучение и тестирование для моей модели, Обучение и тестирование для sklearn модели, перебор различных гиперпараметров с кросс-валидацией, оценка модели, сохранение результатов)
5. SVM (моя реализация, Pipeline для обучения и тестирования, Обучение и тестирование для моей модели, Обучение и тестирование для sklearn модели, перебор различных гиперпараметров с кросс-валидацией, оценка модели, сохранение результатов)
6. Naive Bayes (моя реализация, Pipeline для обучения и тестирования, Обучение и тестирование для моей модели, Обучение и тестирование для sklearn модели, перебор различных гиперпараметров с кросс-валидацией, оценка модели, сохранение результатов)

Accuracy:

	Моя модель	sklearn модель	Best accuracy
Логистическая регрессия	0.8247998152140438	0.8310748383122882	0.8347320603634124
KNN	0.755 *для 2000 данных	0.8324222359100708	0.8324222359100708
SVM	0.8317677856482907	0.9208885124730052	0.9273560209424084
Naive Bayes	0.7935786880197105	0.7935786880197105	0.8302279026793964

Вывод:
В результате лучшую точность для моего датасета дал метод - SVM, при нем точность достигла -92% При этом параметры: C=100, kernel='rbf', degree=3, gamma='scale'. Оказалось очень удобно использовать и работать с pipeline - очень много встроенных функций для обработки данных, так же , мне было интересно попробовать создать свою функцию (заполняет пропущенные значения в столбце arrival_delay_in_minutes
на значения из departure_delay_in_minutes) обработки данных, которую можно было бы использовать в pipeline в моей работе это ffill(data_r) и класс SpInpTransformer() структура которого поддерживается pipeline. Далее pipeline оказался удобен и при обучении и при тестировании и при использовании GridSearch. Было интересно самой попробовать реализовать каждый метод и сравнить точность, проблемы возникли в алгоритмом KNN на моем объеме данных он работал слишком долго (проклятье большой размерности) поэтому мне пришлось обучать его на случайно выбранной подвыборке, что не дало хорошего результата. В каждом случае я реализовывала поиск по сетке при различных параметрах с кросс валидацией для поиска лучших параметров , лучше всего была заметна разница в методе Naive Bayes, тк после использования GridSearch точность увеличилась на 4 процента. Все тестирования сопровождались оценками (таблица с показателем accuracy расположена выше). После нахождения лучших параметров для каждого метода модели сохранялись в соответствующие файлы. Работу было делать интересно, решать проблемы с параметрами , объемами данных, правильным их представлением для обучения или оценки точности и т.д. Я на практике поняла как работает каждый метод, как сложно и порой очень долго (в силу ограниченных вычислительных способностей компьютера) выполняется обучение, тестирование, подбор лучших параметров.

```
import numpy as np              # Массивы (матрицы, векторы, линейная
алгебра)
import matplotlib.pyplot as plt # Научная графика
%matplotlib inline

import pandas as pd             # Таблицы и временные ряды (dataframe,
series)
import seaborn as sns           # Еще больше красивой графики для
визуализации данных
import sklearn                  # Алгоритмы машинного обучения

from google.colab import files
uploaded = files.upload()
```

```
<IPython.core.display.HTML object>

Saving airline_passenger_satisfaction.csv to
airline_passenger_satisfaction.csv
```

```
import io
data_r =
pd.read_csv(io.BytesIO(uploaded['airline_passenger_satisfaction.csv'])
)

data_r.columns
```

```
Index(['Unnamed: 0', 'Gender', 'customer_type', 'age',
'type_of_travel',
       'customer_class', 'flight_distance', 'inflight_wifi_service',
       'departure_arrival_time_convenient', 'ease_of_online_booking',
       'gate_location', 'food_and_drink', 'online_boarding',
'seat_comfort',
       'inflight_entertainment', 'onboard_service',
'leg_room_service',
       'baggage_handling', 'checkin_service', 'inflight_service',
       'cleanliness', 'departure_delay_in_minutes',
'arrival_delay_in_minutes',
       'satisfaction'],
      dtype='object')
```

```
from sklearn.pipeline import Pipeline
from sklearn.impute import SimpleImputer
from sklearn.preprocessing import StandardScaler, OneHotEncoder
from sklearn.model_selection import train_test_split, GridSearchCV
from sklearn.compose import ColumnTransformer

import numpy as np
from sklearn.base import BaseEstimator, ClassifierMixin,
TransformerMixin
from sklearn.utils.validation import check_X_y, check_array,
check_is_fitted
```

```
from collections import Counter
from sklearn.metrics import euclidean_distances

from sklearn.metrics import confusion_matrix
from sklearn.metrics import mean_squared_error

from sklearn.model_selection import GridSearchCV

from sklearn.metrics import accuracy_score

import joblib

from sklearn.metrics import accuracy_score, confusion_matrix,
recall_score, precision_score, roc_curve, classification_report,
ConfusionMatrixDisplay
```

Использование pipeline для предобработки

Напишем свою функцию для заполнения пропущенных значений для arrival_delay_in_minutes, далее трансформеры и объединяем их в общий pipeline. В итоге мы реализовали все пункты сделанные в 0ой работе (кроме визуализации). StandardScaler() - масштабировал (нормализовал данные), SpInpTransformer - заполнил пропущенные значения для arrival_delay_in_minutes, OneHotEncoder - перевел категориальные признаки. ColumnTransformer позволил дополнить необходимые преобразования - удалить не сильно влияющие на уровень удовлетворенности столбцы, выполнить описанные выше преобразования.

```
def ffill(data_r):
  if 'arrival_delay_in_minutes' in data_r:

data_r['arrival_delay_in_minutes'].fillna(data_r['departure_delay_in_m
inutes'], inplace = True)
  return data_r

class SpInpTransformer():
  def __init__(self,f):
    self.func = f

  def transform(self, input_df, **transform_params):
    return self.func(input_df)

  def fit(self, X, y = None, **fit_params):
    return self

drop_feat = ['Gender', 'customer_type', 'age',
       'departure_arrival_time_convenient', 'customer_class',
       'gate_location', 'food_and_drink', 'onboard_service',
'leg_room_service',
```

```
       'baggage_handling', 'checkin_service', 'inflight_service',
       'cleanliness',
'departure_delay_in_minutes','flight_distance','departure_delay_in_min
utes']

numeric_features = ['inflight_wifi_service', 'ease_of_online_booking',
                    'online_boarding', 'seat_comfort',
'inflight_entertainment',
                    'arrival_delay_in_minutes']

numeric_transformer = Pipeline(
    steps=[("imputer", SimpleImputer(strategy="median")),("scaler",
StandardScaler())]
    )

categorical_features = ['type_of_travel']

categorical_transformer = Pipeline(
    steps=[('onehotenc', OneHotEncoder(handle_unknown="ignore"))]
    )

col_transformer = ColumnTransformer(transformers =
                                    [('drop_columns', 'drop',
drop_feat),

('num_processing',numeric_transformer, numeric_features),
                                     ('cat_processing',
categorical_transformer, categorical_features)
                                     ], remainder = 'drop')

X = data_r.drop(['satisfaction','Unnamed: 0'], axis=1)
data_r['satisfaction'] = pd.factorize(data_r['satisfaction'])[0]
y = data_r['satisfaction']

X_train, X_test, y_train, y_test  = train_test_split(X, y,
test_size=0.2, random_state=124)
```

Логистическая регрессия

```
from sklearn.linear_model import LogisticRegression
```

Моя реализация: выполнено наследование от BaseEstimator, ClassifierMixin, реализованы fit и predict в соответствии со стандартами scikit-learn.

```
class Classifier_log_regression(BaseEstimator, ClassifierMixin):

    def __init__(self, lr = 0.0001, n = 100):
        self.lr = lr
        self.n = n
```

```
        self.w = None
        self.b = None

    def fit(self, X, y):

        # Check that X and y have correct shape
        X, y = check_X_y(X, y)

        self.w = np.zeros(X.shape[1])
        self.b = 0

        for _ in range(self.n):
            l_m = np.dot(X, self.w)+ self.b
            pred_labels = self._sigmoid(l_m)

            dw = (1/self.n)*np.dot(X.T, pred_labels - y)
            db = (1/self.n)*np.sum(pred_labels - y)

            self.w -= self.lr * dw
            self.b -= self.lr * db
        # Return the classifier
        return self

    def predict(self, X):

        # Check is fit had been called
        check_is_fitted(self, ['w', 'b'])

        # Input validation
        X = check_array(X)

        l_m =np.dot(X, self.w)+self.b
        pred_labels = self._sigmoid(l_m)
        pred_labels_cls = [1 if i > 0.5 else 0 for i in pred_labels]
        return np.array(pred_labels_cls)

    def _sigmoid(self, x):
        return 1/(1+np.exp(-x))
```

pipeline для последубщего обучения и тестирования

```
my_clf = Pipeline(
    [
        ("fill_spaces", SpInpTransformer(ffill)),
        ("transform_column", col_transformer),
        ("model", Classifier_log_regression())
    ])
clf = Pipeline(
    [
        ("fill_spaces", SpInpTransformer(ffill)),
```

```
        ("transform_column", col_transformer),
        ("model", LogisticRegression())
    ])
```

Обучение и тестирование для моей модели:

```
print('for my model:')
my_clf.fit(X_train, y_train)
y_pred_test = my_clf.predict(X_test)
y_pred_train = my_clf.predict(X_train)
print('confusion_matrix for test \n', confusion_matrix(y_test,
y_pred_test))
print('confusion_matrix for train \n', confusion_matrix(y_train,
y_pred_train))
MSE_train = mean_squared_error(y_train, y_pred_train)
MSE_test  = mean_squared_error(y_test,  y_pred_test)
print('MSE train = ', MSE_train, 'MSE test = ', MSE_test)
acc_train = accuracy_score(y_train, y_pred_train)
acc_test = accuracy_score(y_test,  y_pred_test)
print('acc train = ', acc_train, 'acc test = ', acc_test)
```

```
for my model:
confusion_matrix for test
 [[12359  2251]
 [ 2300  9066]]
confusion_matrix for train
 [[49779  9063]
 [ 8767 36295]]
MSE train =  0.1716007083461657 MSE test =  0.17520018478595628
acc train =  0.8283992916538343 acc test =  0.8247998152140438
```

Обучение и тестирование для sklearn модели:

```
print('for sklern model:')
clf.fit(X_train, y_train)
print("model score: %.3f" % clf.score(X_test, y_test))
y_pred_test = clf.predict(X_test)
y_pred_train = clf.predict(X_train)
print('confusion_matrix for test \n', confusion_matrix(y_test,
y_pred_test))
print('confusion_matrix for train \n', confusion_matrix(y_train,
y_pred_train))
MSE_train = mean_squared_error(y_train, y_pred_train)
MSE_test  = mean_squared_error(y_test,  y_pred_test)
print('MSE train = ', MSE_train, 'MSE test = ', MSE_test)
acc_train = accuracy_score(y_train, y_pred_train)
acc_test = accuracy_score(y_test,  y_pred_test)
print('acc train = ', acc_train, 'acc test = ', acc_test)
```

```
for sklern model:
model score: 0.831
```

```
confusion_matrix for test
 [[12444  2166]
 [ 2222  9144]]
confusion_matrix for train
 [[50112  8730]
 [ 8437 36625]]
MSE train =  0.16521981829380966 MSE test =  0.16892516168771174
acc train =  0.8347801817061903 acc test =  0.8310748383122882
```

Результат встроенной модели оказался лучше примерно на 1 процент, я думаю это связано с большим количеством варьируемых параметров в sklearn.

Реализуем поиск по сетке с кросс-валидацией

```
parameters = {'model__C': np.logspace(-10, 10, 20), 'model__penalty':
['l1', 'l2'], 'model__solver':['liblinear']}

grid_search = GridSearchCV(clf,
                           param_grid = parameters,
                           cv = 5)

grid_search.fit(X_train, y_train)
```

```
GridSearchCV(cv=5,
             estimator=Pipeline(steps=[('fill_spaces',
                                        <__main__.SpInpTransformer
object at 0x7f6ca3b49750>),
                                       ('transform_column',

ColumnTransformer(transformers=[('drop_columns',

'drop',

['Gender',

'customer_type',

'age',

'departure_arrival_time_convenient',

'customer_class',

'gate_location',

'food_and_drink',

'onboard_service',
```

```
'leg_room_service',

'baggage_h...
             param_grid={'model__C': array([1.00000000e-10,
1.12883789e-09, 1.27427499e-08, 1.43844989e-07,
       1.62377674e-06, 1.83298071e-05, 2.06913808e-04, 2.33572147e-03,
       2.63665090e-02, 2.97635144e-01, 3.35981829e+00, 3.79269019e+01,
       4.28133240e+02, 4.83293024e+03, 5.45559478e+04, 6.15848211e+05,
       6.95192796e+06, 7.84759970e+07, 8.85866790e+08,
1.00000000e+10]),
                         'model__penalty': ['l1', 'l2'],
                         'model__solver': ['liblinear']})

print('Best Params:', grid_search.best_params_)
print('Best score:', grid_search.best_score_)
print(grid_search.best_estimator_.get_params()['model'])

Best Params: {'model__C': 0.002335721469090121, 'model__penalty':
'l1', 'model__solver': 'liblinear'}
Best score: 0.8414594280080842
LogisticRegression(C=0.002335721469090121, penalty='l1',
solver='liblinear')
```

В результате лучшими параметрами оказались 'model__C': 0.002335721469090121, 'model__penalty': 'l1'

```
y_pred_test = grid_search.predict(X_test)
acc_test = accuracy_score(y_test,  y_pred_test)
acc_test

0.8347320603634124
```

Но точность на тестовой выборке практически не изменилась.

Получим еще оценки:

```
recall_score(y_test, y_pred_test)

0.8005454865388

precision_score(y_test, y_pred_test)

0.8178876404494382

from sklearn.metrics import auc

fpr, tpr, thresholds = roc_curve(y_test, y_pred_test, pos_label=1)
print('fpr: ' + str(fpr))
print('tpr: ' + str(tpr))
print('thresholds: ' + str(thresholds))
```

```
AUC = auc(fpr, tpr)
print('AUC: ' + str(AUC))

print('\n\n')
plt.plot(fpr, tpr)
plt.title('ROC_curve' + '(AUC: ' + str(AUC) + ')' )
plt.ylabel('True Positive Rate')
plt.xlabel('False Positive Rate')
plt.show()
```

```
fpr: [0.         0.13867214 1.        ]
tpr: [0.         0.80054549 1.        ]
thresholds: [2 1 0]
AUC: 0.8309366720852795
```

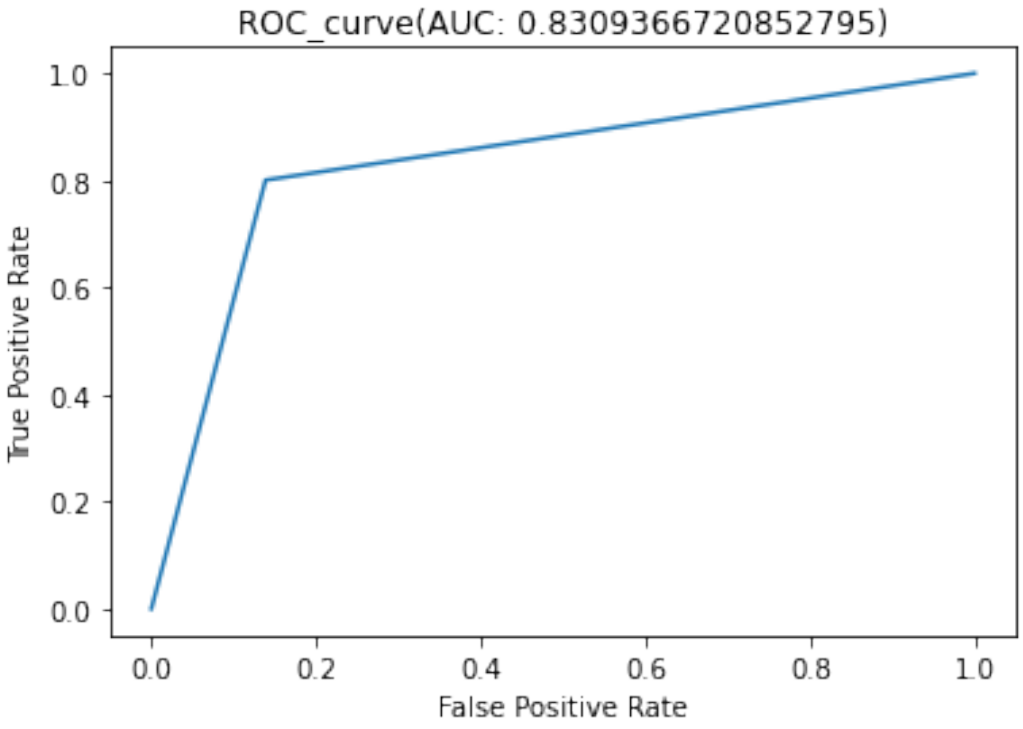

Сохраним эти гиперпараметры в файл, вместе с обученной моделью

```
joblib.dump(grid_search, "log_reg_model.pkl")
```

```
['log_reg_model.pkl']
```

проверим

```
clf_log_reg = joblib.load("log_reg_model.pkl")
y_pred = clf_log_reg.predict(X_test)

accuracy_score(y_test, y_pred)

0.8347320603634124
```

KNN

```
from sklearn.neighbors import KNeighborsRegressor

from sklearn.decomposition import PCA
```

Моя реализация: выполнено наследование от BaseEstimator, ClassifierMixin, реализованы fit и predict в соответствии со стандартами scikit-learn.

```
def eucl_dist(x1, x2):
      return np.sqrt(np.sum(x1-x2)**2)

class Classifier_knn(BaseEstimator, ClassifierMixin):

    def __init__(self, k = 20):
        self.k = k

    def fit(self, X, y):

        # Check that X and y have correct shape
        X, y = check_X_y(X, y)

        self.X = X
        self.y = y
        # Return the classifier
        return self

    def predict(self, X):

        # Check is fit had been called
        check_is_fitted(self, ['X', 'y'])

        # Input validation
        X = check_array(X)

        pred_labels = [self.pred_for_each(x) for x in X]
        return np.array(pred_labels)

    def pred_for_each(self, x):
        dist = [eucl_dist(x, xx) for xx in self.X]
        idx = np.argsort(dist)[:self.k]
        labels = [self.y[i] for i in idx]
```

```
        most_common = Counter(labels).most_common(1)
        return most_common[0][0]
```

pipeline для последубщего обучения и тестирования

```
my_clf = Pipeline(
    [
        ("fill_spaces", SpInpTransformer(ffill)),
        ("transform_column", col_transformer),
        ("model", Classifier_knn())
    ])
clf = Pipeline(
    [
        ("fill_spaces", SpInpTransformer(ffill)),
        ("transform_column", col_transformer),
        ('pca', PCA()),
        ("model", KNeighborsRegressor())
    ])
```

Обучение и тестирование для моей модели:

```
data_r = data_r.sample(n=10000, replace=False, axis=0)
X1 = data_r.drop(['satisfaction','Unnamed: 0'], axis=1)
data_r['satisfaction'] = pd.factorize(data_r['satisfaction'])[0]
y1 = data_r['satisfaction']

X_train1, X_test1, y_train1, y_test1  = train_test_split(X1, y1,
test_size=0.2, random_state=124)

X_test1.shape

(2000, 22)

print('for my model:')
my_clf.fit(X_train1, y_train1)
y_pred_test = my_clf.predict(X_test1)
y_pred_train = my_clf.predict(X_train1)
print('confusion_matrix for test \n', confusion_matrix(y_test1,
y_pred_test))
print('confusion_matrix for train \n', confusion_matrix(y_train1,
y_pred_train))
MSE_train = mean_squared_error(y_train1, y_pred_train)
MSE_test  = mean_squared_error(y_test1,  y_pred_test)
print('MSE train = ', MSE_train, 'MSE test = ', MSE_test)
acc_train = accuracy_score(y_train1, y_pred_train)
acc_test = accuracy_score(y_test1,  y_pred_test)
print('acc train = ', acc_train, 'acc test = ', acc_test)

for my model:
confusion_matrix for test
 [[903 231]
 [259 607]]
```

```
confusion_matrix for train
 [[3789  709]
 [ 890 2612]]
MSE train =  0.199875 MSE test =  0.245
acc train =  0.800125 acc test =  0.755
```

Обучение и тестирование для sklearn модели:

```
grid_searcher = GridSearchCV(
    clf,
    param_grid={
        'pca__n_components': [2, 3, 4, 5, 6, 7],
        'model__n_neighbors': range(5, 30, 5),
        'model__weights': ['distance'],
        'model__p': [2]
    },
    cv=3
)
```

```
%%time

grid_searcher.fit(X_train, y_train)
```

```
CPU times: user 1min 25s, sys: 26.9 s, total: 1min 52s
Wall time: 1min 23s
```

```
GridSearchCV(cv=3,
             estimator=Pipeline(steps=[('fill_spaces',
                                        <__main__.SpInpTransformer
object at 0x7efc8e1638d0>),
                                       ('transform_column',

ColumnTransformer(transformers=[('drop_columns',

'drop',

['Gender',

'customer_type',

'age',

'departure_arrival_time_convenient',

'customer_class',

'gate_location',

'food_and_drink',
```

```
'onboard_service',

'leg_room_service',

'baggage_h...

'seat_comfort',

'inflight_entertainment',

'arrival_delay_in_minutes']),

('cat_processing',

Pipeline(steps=[('onehotenc',

OneHotEncoder(handle_unknown='ignore'))]),

['type_of_travel'])])),
                                        ('pca', PCA()),
                                        ('model',
KNeighborsRegressor())]),
             param_grid={'model__n_neighbors': range(5, 30, 5),
'model__p': [2],
                         'model__weights': ['distance'],
                         'pca__n_components': [2, 3, 4, 5, 6, 7]})
```

Рассмотрим предсказание лучшей модели

```
y_pred_test = grid_searcher.predict(X_test).astype(int)
y_pred_train = grid_searcher.predict(X_train).astype(int)
print('confusion_matrix for test \n', confusion_matrix(y_test,
y_pred_test))
print('confusion_matrix for train \n', confusion_matrix(y_train,
y_pred_train))
MSE_train = mean_squared_error(y_train, y_pred_train)
MSE_test  = mean_squared_error(y_test,  y_pred_test)
print('MSE train = ', MSE_train, 'MSE test = ', MSE_test)
acc_train = accuracy_score(y_train, y_pred_train)
acc_test = accuracy_score(y_test,  y_pred_test)
print('acc train = ', acc_train, 'acc test = ', acc_test)
```

```
confusion_matrix for test
 [[14578    32]
 [ 4321  7045]]
confusion_matrix for train
 [[58818    24]
 [16579 28483]]
MSE train =  0.15979173082845705 MSE test =  0.16757776408992917
acc train =  0.840208269171543 acc test =  0.8324222359100708
```

Точность предсказания на тестовой выборке гораздо лучше чем у моей модели. Думаю, это связано с тем что при применении классического алгоритмя всего объема данных было слишком много, поэтому при обучении на части данных предсказание оказалось хуже.

```
grid_searcher.best_params_
```

```
{'model__n_neighbors': 25,
 'model__p': 2,
 'model__weights': 'distance',
 'pca__n_components': 7}
```

Получим еще оценки:

```
recall_score(y_test, y_pred_test)
```

```
0.6198310751363716
```

```
precision_score(y_test, y_pred_test)
```

```
0.9954783100183694
```

```
from sklearn.metrics import auc

fpr, tpr, thresholds = roc_curve(y_test, y_pred_test, pos_label=1)
print('fpr: ' + str(fpr))
print('tpr: ' + str(tpr))
print('thresholds: ' + str(thresholds))


AUC = auc(fpr, tpr)
print('AUC: ' + str(AUC))

print('\n\n')
plt.plot(fpr, tpr)
plt.title('ROC_curve' + '(AUC: ' + str(AUC) + ')' )
plt.ylabel('True Positive Rate')
plt.xlabel('False Positive Rate')
plt.show()
```

```
fpr: [0.         0.00219028 1.        ]
tpr: [0.         0.61983108 1.        ]
thresholds: [2 1 0]
AUC: 0.808820397253333
```

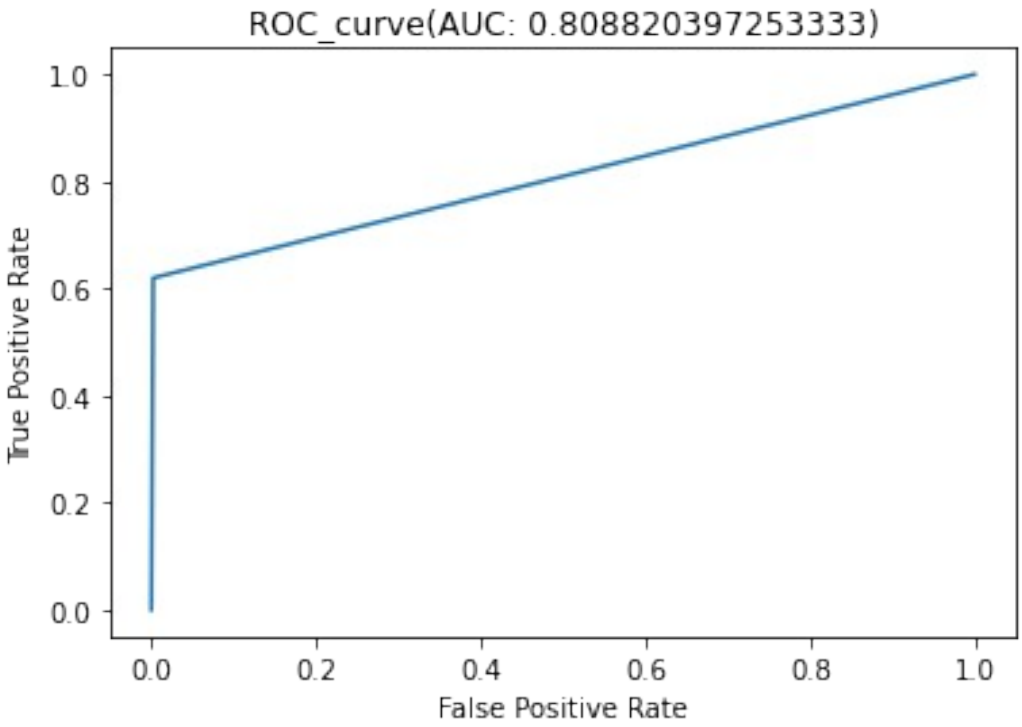

Сохраним эти гиперпараметры в файл, вместе с обученной моделью

```
joblib.dump(grid_searcher, "knn_model.pkl")
```

```
['knn_model.pkl']
```

проверим

```
clf_knn = joblib.load("knn_model.pkl")
y_pred = clf_knn.predict(X_test)
```

```
accuracy_score(y_test, y_pred.astype(int))
```

```
0.8324222359100708
```

SVM

```
from sklearn.svm import SVC
```

Моя реализация: выполнено наследование от BaseEstimator, ClassifierMixin, реализованы fit и predict в соответствии со стандартами scikit-learn.

```
class SVM_classifier(BaseEstimator, ClassifierMixin):

    def __init__(self, lr = 0.001, lambd = 0.01, n = 1000):
        self.lr = lr
        self.lambd = lambd
        self.n = n
```

```
        self.w = None
        self.b = None

    def fit(self, X, y):

        # Check that X and y have correct shape
        X, y = check_X_y(X, y)

        y_ = np.where(y <= 0, -1, 1)
        n_samp, n_ft = X.shape

        self.w = np.zeros(n_ft)
        self.b = 0

        for _ in range(self.n):
          for idx, x_i in enumerate(X):
            cond = y_[idx] * (np.dot(x_i, self.w)-self.b) >= 1
            if cond:
              self.w -= self.lr * (2*self.lambd*self.w)
            else:
              self.w -= self.lr * (2*self.lambd*self.w - np.dot(x_i,
y_[idx]))
              self.b -= self.lr * y_[idx]
        # Return the classifier
        return self

    def predict(self, X):

        # Check is fit had been called
        check_is_fitted(self, ['w', 'b'])

        # Input validation
        X = check_array(X)

        l_o =np.dot(X, self.w) - self.b
        return np.sign(l_o)
```

pipeline для последубщего обучения и тестирования

```
my_clf = Pipeline(
    [
        ("fill_spaces", SpInpTransformer(ffill)),
        ("transform_column", col_transformer),
        ("method", SVM_classifier())
    ])
clf = Pipeline(
    [
        ("fill_spaces", SpInpTransformer(ffill)),
        ("transform_column", col_transformer),
```

```
        ("model", SVC())
    ])
```

Обучение и тестирование для моей модели:

```
y_train2 = np.where(y_train==0, -1,1)
y_test2 = np.where(y_test==0, -1,1)

print('for my model:')
my_clf.fit(X_train, y_train2)
y_pred_test = my_clf.predict(X_test)
y_pred_train = my_clf.predict(X_train)

for my model:

print('confusion_matrix for test \n', confusion_matrix(y_test2,
y_pred_test))
print('confusion_matrix for train \n', confusion_matrix(y_train2,
y_pred_train))
MSE_train = mean_squared_error(y_train2, y_pred_train)
MSE_test  = mean_squared_error(y_test2,  y_pred_test)
print('MSE train = ', MSE_train, 'MSE test = ', MSE_test)
acc_train = accuracy_score(y_train2, y_pred_train)
acc_test = accuracy_score(y_test2,  y_pred_test)
print('acc train = ', acc_train, 'acc test = ', acc_test)

confusion_matrix for test
 [[12503  2107]
 [ 2263  9103]]
confusion_matrix for train
 [[50419  8423]
 [ 8608 36454]]
MSE train =  0.6556436710809979 MSE test =  0.672928857406837
acc train =  0.8360890822297505 acc test =  0.8317677856482907
```

Обучение и тестирование для sklearn модели:

```
print('for sklern model:')
clf.fit(X_train, y_train)
print("model score: %.3f" % clf.score(X_test, y_test))
y_pred_test = clf.predict(X_test)
y_pred_train = clf.predict(X_train)
print('confusion_matrix for test \n', confusion_matrix(y_test,
y_pred_test))
print('confusion_matrix for train \n', confusion_matrix(y_train,
y_pred_train))
MSE_train = mean_squared_error(y_train, y_pred_train)
MSE_test  = mean_squared_error(y_test,  y_pred_test)
print('MSE train = ', MSE_train, 'MSE test = ', MSE_test)
acc_train = accuracy_score(y_train, y_pred_train)
acc_test = accuracy_score(y_test,  y_pred_test)
print('acc train = ', acc_train, 'acc test = ', acc_test)
```

```
for sklern model:
model score: 0.921
confusion_matrix for test
 [[13580  1030]
 [ 1025 10341]]
confusion_matrix for train
 [[54730  4112]
 [ 4199 40863]]
MSE train =  0.07998729596550662 MSE test =  0.07911148752694795
acc train =  0.9200127040344934 acc test =  0.920888512473052
```

Отличная точность предсказаний, пока эта модель лучше всего подходит для данного датасета.

Реализуем поиск по сетке с кросс-валидацией

```
param_grid = {'model__C':[0.1,1,10,100],}
grid = GridSearchCV(clf,
                    param_grid,
                    refit = True,
                    verbose=2,
                    cv = 5)

grid.fit(X_train, y_train)
```

```
Fitting 5 folds for each of 4 candidates, totalling 20 fits
[CV] END .....................................model__C=0.1; total
time= 2.9min
[CV] END .....................................model__C=0.1; total
time= 2.5min
[CV] END .....................................model__C=0.1; total
time= 2.5min
[CV] END .....................................model__C=0.1; total
time= 2.4min
[CV] END .....................................model__C=0.1; total
time= 2.5min
[CV] END .......................................model__C=1; total
time= 2.3min
[CV] END .......................................model__C=1; total
time= 2.2min
[CV] END .......................................model__C=1; total
time= 2.3min
[CV] END .......................................model__C=1; total
time= 2.4min
[CV] END .......................................model__C=1; total
time= 2.4min
[CV] END ......................................model__C=10; total
time= 3.8min
[CV] END ......................................model__C=10; total
time= 3.5min
[CV] END ......................................model__C=10; total
```

```
time= 3.6min
[CV] END .....................................model__C=10; total
time= 4.1min
[CV] END .....................................model__C=10; total
time= 3.8min
[CV] END ....................................model__C=100; total
time=13.6min
[CV] END ....................................model__C=100; total
time=14.1min
[CV] END ....................................model__C=100; total
time=13.5min
[CV] END ....................................model__C=100; total
time=12.3min
[CV] END ....................................model__C=100; total
time=13.0min

GridSearchCV(cv=5,
             estimator=Pipeline(steps=[('fill_spaces',
                                        <__main__.SpInpTransformer
object at 0x7f6ca12184d0>),
                                       ('transform_column',

ColumnTransformer(transformers=[('drop_columns',

'drop',

['Gender',

'customer_type',

'age',

'departure_arrival_time_convenient',

'customer_class',

'gate_location',

'food_and_drink',

'onboard_service',

'leg_room_service',

'baggage_h...

SimpleImputer(strategy='median')),

('scaler',
```

```
StandardScaler())]),

['inflight_wifi_service',

'ease_of_online_booking',

'online_boarding',

'seat_comfort',

'inflight_entertainment',

'arrival_delay_in_minutes']),

('cat_processing',

Pipeline(steps=[('onehotenc',

OneHotEncoder(handle_unknown='ignore'))]),

['type_of_travel'])])),
                                       ('model', SVC())]),
             param_grid={'model__C': [0.1, 1, 10, 100]}, verbose=2)
```

Лучшие параметры:

```
print('Best Params:', grid.best_params_)
print('Best score:', grid.best_score_)
print(grid.best_estimator_.get_params()['model'])
```

```
Best Params: {'model__C': 100}
Best score: 0.926133748997694
SVC(C=100)
```

```
y_pred_test = grid.predict(X_test)
acc_test = accuracy_score(y_test,  y_pred_test)
acc_test
```

```
0.9273560209424084
```

Получим оценки :

```
recall_score(y_test, y_pred_test)
```

```
0.9113144465951082
```

```
precision_score(y_test, y_pred_test)
```

```
0.921776274806443
```

```
from sklearn.metrics import auc

fpr, tpr, thresholds = roc_curve(y_test, y_pred_test, pos_label=1)
print('fpr: ' + str(fpr))
print('tpr: ' + str(tpr))
print('thresholds: ' + str(thresholds))


AUC = auc(fpr, tpr)
print('AUC: ' + str(AUC))

print('\n\n')
plt.plot(fpr, tpr)
plt.title('ROC_curve' + '(AUC: ' + str(AUC) + ')' )
plt.ylabel('True Positive Rate')
plt.xlabel('False Positive Rate')
plt.show()
```

```
fpr: [0.         0.06016427 1.        ]
tpr: [0.         0.91131445 1.        ]
thresholds: [2 1 0]
AUC: 0.9255750877739402
```

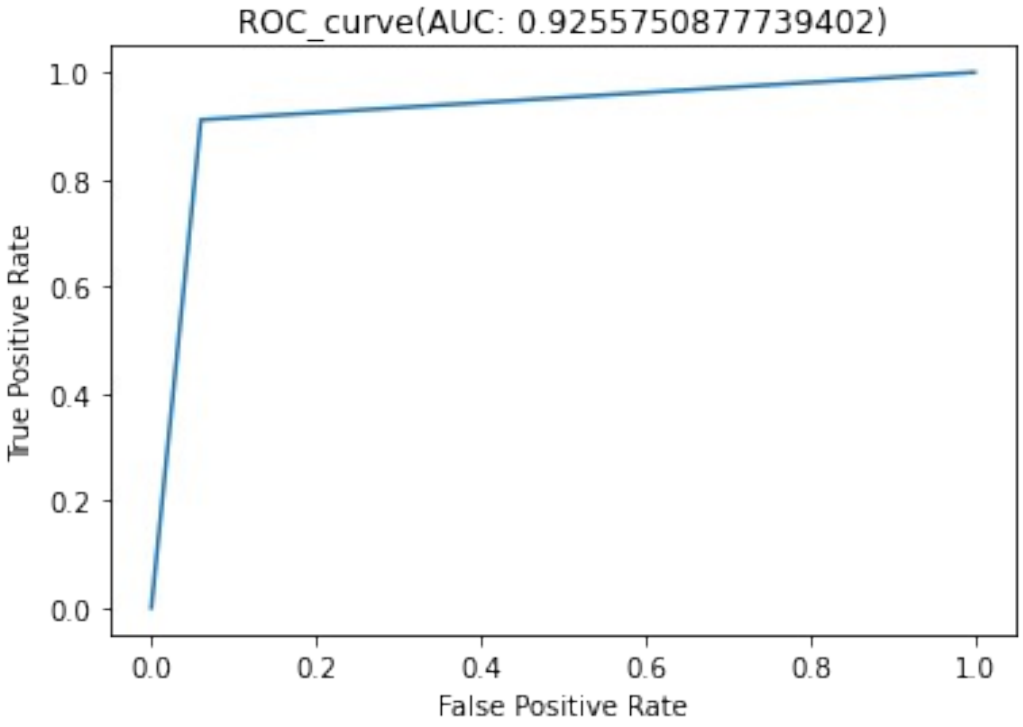

Сохранение в файл и проверка

```
joblib.dump(grid, "SVM_model.pkl")
clf_SVM = joblib.load("SVM_model.pkl")
y_pred = clf_SVM.predict(X_test)
accuracy_score(y_test, y_pred)
```

```
0.9273560209424084
```

Naive Bayes

```
from sklearn.naive_bayes import GaussianNB
```

Моя реализация: выполнено наследование от BaseEstimator, ClassifierMixin, реализованы fit и predict в соответствии со стандартами scikit-learn.

Гауссовский наивный байесовский алгоритм для классификации. Предполагается, что вероятность появления признаков гауссова

```
class Classifier_NB(BaseEstimator, ClassifierMixin):

    def fit(self, X, y):

        # Check that X and y have correct shape
        X, y = check_X_y(X, y)

        n_samp, n_ft = X.shape
        self._classes = np.unique(y)
        n_cl = len(self._classes)
        self._mean = np.zeros((n_cl, n_ft), dtype = np.float64)
        self._var = np.zeros((n_cl, n_ft), dtype = np.float64)
        self._priors = np.zeros(n_cl, dtype = np.float64)

        for classes in self._classes:
          X_c = X[classes == y]
          self._mean[classes,:] = X_c.mean(axis = 0)
          self._var[classes,:] = X_c.var(axis = 0)
          self._priors[classes] = X_c.shape[0] / float(n_samp)
        # Return the classifier
        return self

    def predict(self, X):

        # Check is fit had been called
        check_is_fitted(self, ['_mean', '_var', '_priors'])

        # Input validation
        X = check_array(X)

        pred_labels = [self.pred_for_each(x) for x in X]
        return np.array(pred_labels)
```

```
    def pred_for_each(self, x):
        posts =[]

        for idx, c in enumerate(self._classes):
          prior = np.log(self._priors[idx])
          class_cond = np.sum(np.log(self._pdf(idx, x)))
          post = prior + class_cond
          posts.append(post)

        return self._classes[np.argmax(posts)]

    def _pdf(self, class_idx, x):
      mean = self._mean[class_idx]
      var = self._var[class_idx]
      return (np.exp(-(x-mean)**2/(2*var)))/(np.sqrt(2*np.pi*var))
```

pipeline для последубщего обучения и тестирования

```
my_clf = Pipeline(
    [
        ("fill_spaces", SpInpTransformer(ffill)),
        ("transform_column", col_transformer),
        ("model", Classifier_NB())
    ])
clf = Pipeline(
    [
        ("fill_spaces", SpInpTransformer(ffill)),
        ("transform_column", col_transformer),
        ("model", GaussianNB())
    ])
```

Обучение и тестирование для моей модели:

```
print('for my model:')
my_clf.fit(X_train, y_train)
y_pred_test = my_clf.predict(X_test)
y_pred_train = my_clf.predict(X_train)
print('confusion_matrix for test \n', confusion_matrix(y_test,
y_pred_test))
print('confusion_matrix for train \n', confusion_matrix(y_train,
y_pred_train))
MSE_train = mean_squared_error(y_train, y_pred_train)
MSE_test  = mean_squared_error(y_test,  y_pred_test)
print('MSE train = ', MSE_train, 'MSE test = ', MSE_test)
acc_train = accuracy_score(y_train, y_pred_train)
acc_test = accuracy_score(y_test,  y_pred_test)
print('acc train = ', acc_train, 'acc test = ', acc_test)
```

```
for my model:
```

```
/usr/local/lib/python3.7/dist-packages/ipykernel_launcher.py:39:
RuntimeWarning: divide by zero encountered in log

confusion_matrix for test
 [[10782  3828]
 [ 1534  9832]]
confusion_matrix for train
 [[43669 15173]
 [ 5894 39168]]
MSE train =  0.20275446566060978 MSE test =  0.20642131198028948
acc train =  0.7972455343393902 acc test =  0.7935786880197105
```

Обучение и тестирование для sklearn модели:

```
print('for sklern model:')
clf.fit(X_train, y_train)
print("model score: %.3f" % clf.score(X_test, y_test))
y_pred_test = clf.predict(X_test)
y_pred_train = clf.predict(X_train)
print('confusion_matrix for test \n', confusion_matrix(y_test,
y_pred_test))
print('confusion_matrix for train \n', confusion_matrix(y_train,
y_pred_train))
MSE_train = mean_squared_error(y_train, y_pred_train)
MSE_test  = mean_squared_error(y_test,  y_pred_test)
print('MSE train = ', MSE_train, 'MSE test = ', MSE_test)
acc_train = accuracy_score(y_train, y_pred_train)
acc_test = accuracy_score(y_test,  y_pred_test)
print('acc train = ', acc_train, 'acc test = ', acc_test)
```

```
for sklern model:
model score: 0.794
confusion_matrix for test
 [[10782  3828]
 [ 1534  9832]]
confusion_matrix for train
 [[43669 15173]
 [ 5894 39168]]
MSE train =  0.20275446566060978 MSE test =  0.20642131198028948
acc train =  0.7972455343393902 acc test =  0.7935786880197105
```

Результаты встроенной модели и нашей оказались одинаковыми.

Реализуем поиск по сетке с кросс-валидацией

```
parameters = {
    'model__var_smoothing': np.logspace(0,-9, num=100)
}
grid_search = GridSearchCV(clf,
                           param_grid = parameters,
                           cv = 5)
```

```
grid_search.fit(X_train, y_train)
```

```
GridSearchCV(cv=5,
             estimator=Pipeline(steps=[('fill_spaces',
                                        <__main__.SpInpTransformer
object at 0x7fadb9088310>),
                                       ('transform_column',

ColumnTransformer(transformers=[('drop_columns',

'drop',

['Gender',

'customer_type',

'age',

'departure_arrival_time_convenient',

'customer_class',

'gate_location',

'food_and_drink',

'onboard_service',

'leg_room_service',

'baggage_h...
       1.23284674e-07, 1.00000000e-07, 8.11130831e-08, 6.57933225e-08,
       5.33669923e-08, 4.32876128e-08, 3.51119173e-08, 2.84803587e-08,
       2.31012970e-08, 1.87381742e-08, 1.51991108e-08, 1.23284674e-08,
       1.00000000e-08, 8.11130831e-09, 6.57933225e-09, 5.33669923e-09,
       4.32876128e-09, 3.51119173e-09, 2.84803587e-09, 2.31012970e-09,
       1.87381742e-09, 1.51991108e-09, 1.23284674e-09, 1.00000000e-
09])})
```

Лучшие параметры:

```
print('Best Params:', grid_search.best_params_)
print('Best score:', grid_search.best_score_)
print(grid_search.best_estimator_.get_params()['model'])
```

```
Best Params: {'model__var_smoothing': 0.23101297000831597}
Best score: 0.835550130262156
GaussianNB(var_smoothing=0.23101297000831597)
```

```
y_pred_test = grid_search.predict(X_test)
acc_test = accuracy_score(y_test,  y_pred_test)
acc_test
```

```
0.8302279026793964
```

С новыми параметрами точность улучшилась на 4 процента

Получим еще оценки:

```
recall_score(y_test, y_pred_test)
```

```
0.8448002815414394
```

```
precision_score(y_test, y_pred_test)
```

```
0.7839647289353364
```

```
from sklearn.metrics import auc

fpr, tpr, thresholds = roc_curve(y_test, y_pred_test, pos_label=1)
print('fpr: ' + str(fpr))
print('tpr: ' + str(tpr))
print('thresholds: ' + str(thresholds))


AUC = auc(fpr, tpr)
print('AUC: ' + str(AUC))

print('\n\n')
plt.plot(fpr, tpr)
plt.title('ROC_curve' + '(AUC: ' + str(AUC) + ')' )
plt.ylabel('True Positive Rate')
plt.xlabel('False Positive Rate')
plt.show()
```

```
fpr: [0.         0.18110883 1.        ]
tpr: [0.         0.84480028 1.        ]
thresholds: [2 1 0]
AUC: 0.8318457259863254
```

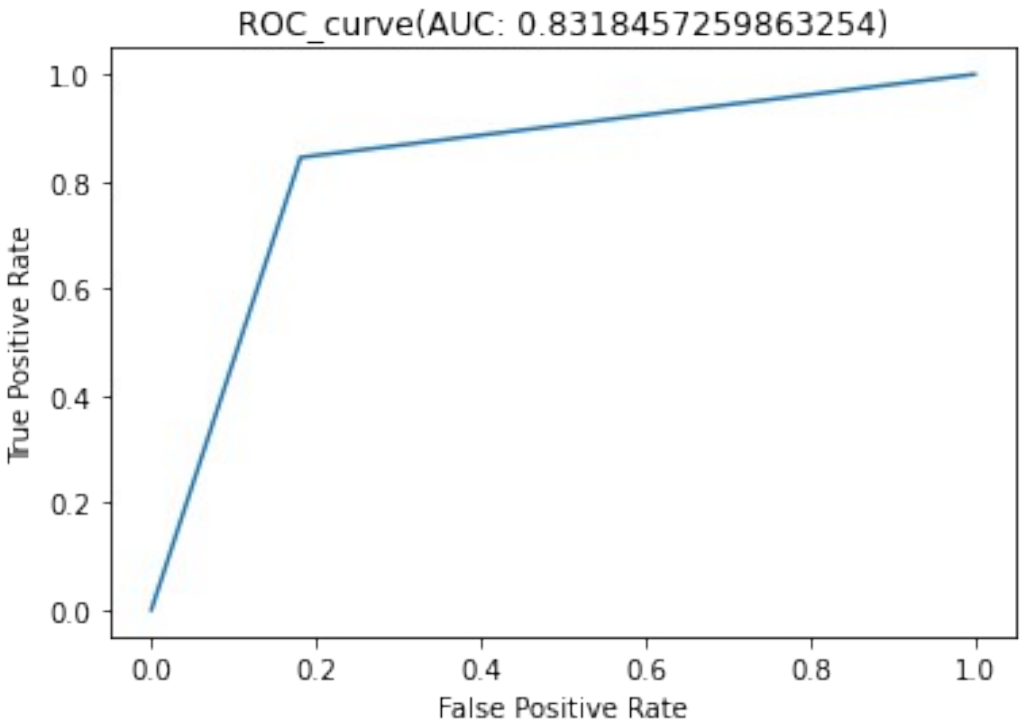

Сохранение в файл и проверка

```
joblib.dump(grid_search, "naive_bayes_model.pkl")
clf_naive_bayes = joblib.load("naive_bayes_model.pkl")
y_pred = clf_naive_bayes.predict(X_test)
accuracy_score(y_test, y_pred)
```

```
0.8302279026793964
```